Recuperación de información en BBC News

Seis buscadores, 2,126 noticias, 115 consultas



Carpio Angeles Leo Yahir
Jaramillo Salmerón Arturo
Mera Montiel Gonzalo Sebastián
Moctezuma Ramírez Diego Rafael
Ramírez Maza Luis Alfredo
Ruiz Juárez Bruno

Minería de Textos · Ciencia de Datos

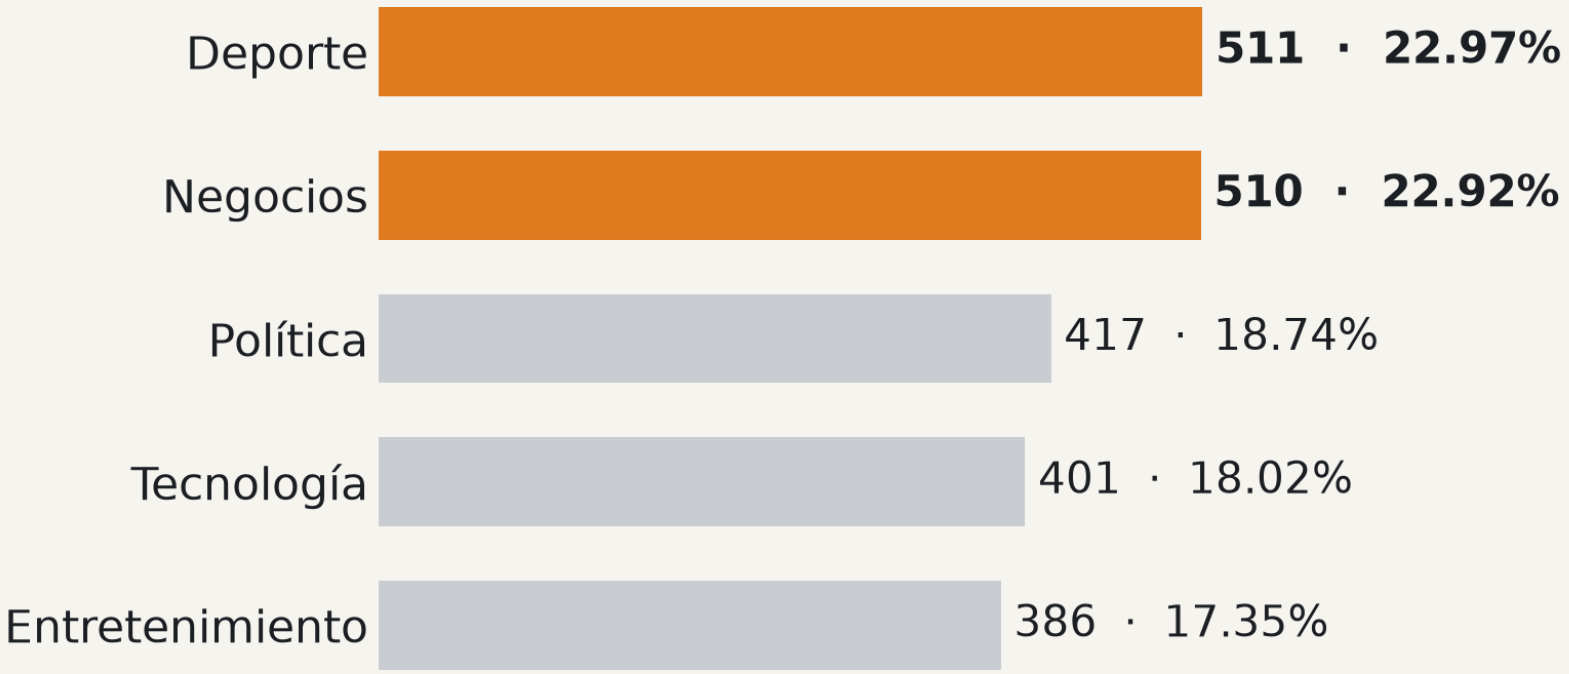
Encontrar la noticia correcta entre 2,225 exige un buscador, no paciencia

2,225

Noticias de la BBC

Cinco categorías. Probamos seis formas de ordenar las noticias por su parecido con la consulta.

Deporte y negocios suman 45.89% de las 2,225 noticias



Ninguna categoría domina: cada una tiene entre 386 y 511 noticias.

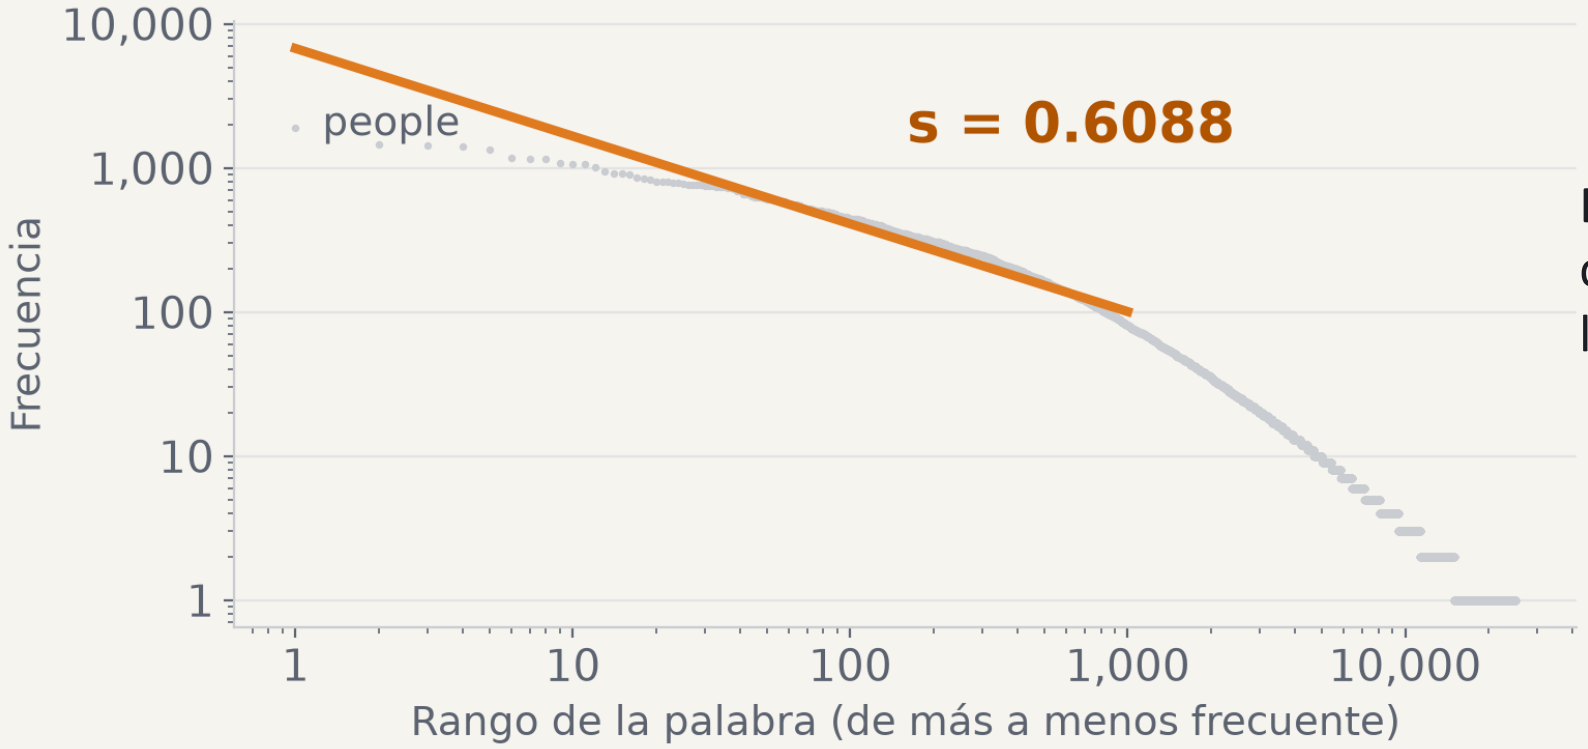
99 noticias estaban duplicadas y quedaron 2,126 documentos únicos

2,126

documentos únicos

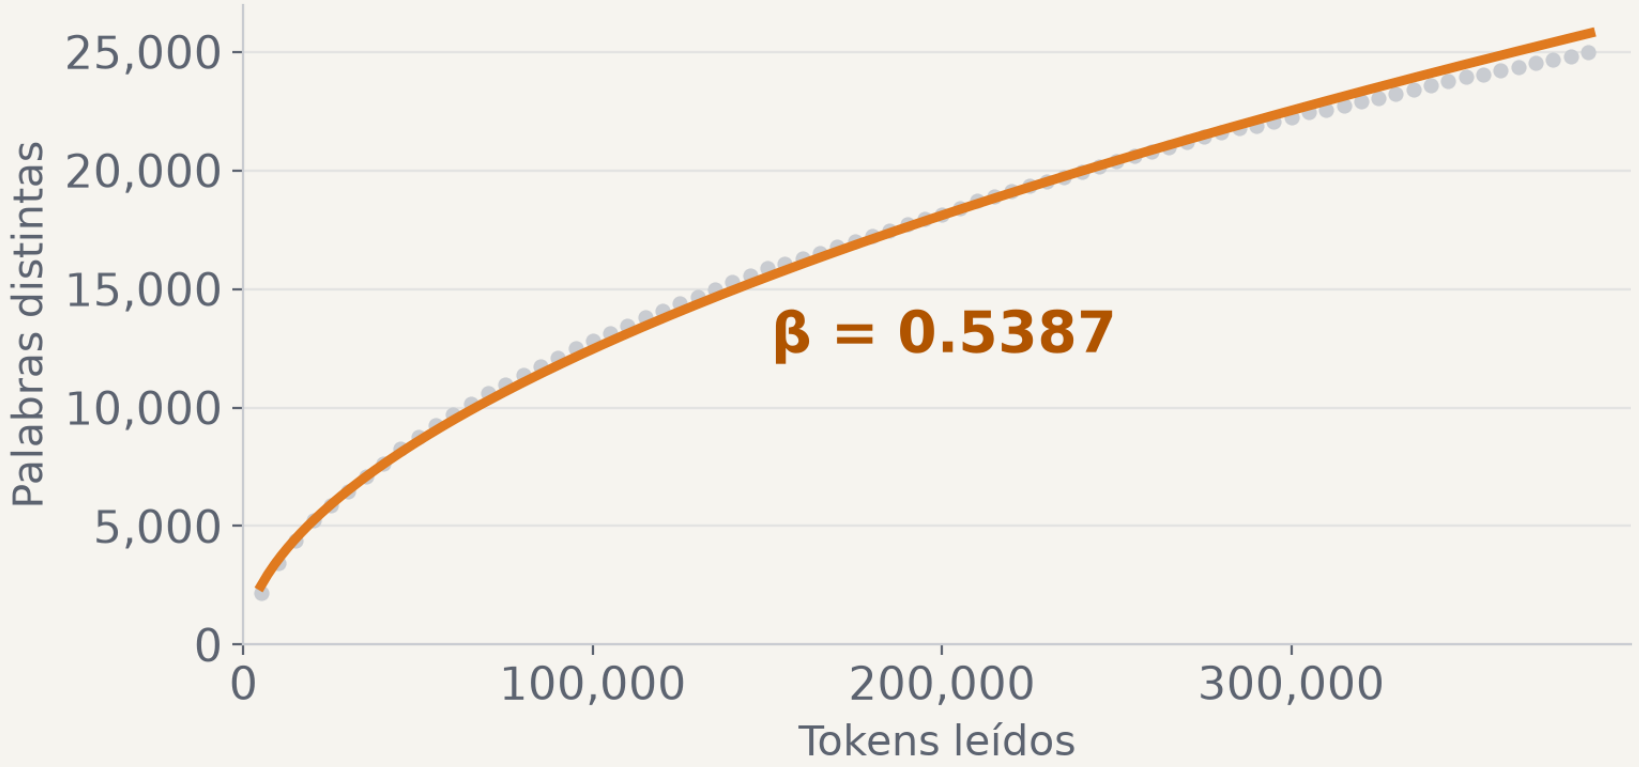
Eran 99 pares de textos idénticos con la misma categoría; dejarlos podría inflar los aciertos.

Pocas palabras dominan el corpus: la frecuencia cae con exponente s = 0.6088



El exponente es bajo porque se quitaron las stopwords. El ajuste cubre los rangos 1 a 1,000 ($R^2 = 0.9469$).

El vocabulario no deja de crecer: β = 0.5387



Hay 24,971 palabras distintas en 385,689 tokens, y 39.97% aparece una sola vez.

Cada categoría tiene su propia huella de palabras



Deporte

Tenistas y técnicos: roddick, nadal, mourinho, wenger.



Política

Partidos y casos: tory, ukip, blunkett, asylum.



Tecnología

Internet y consolas: spam, browser, wifi, psp.

La consulta se convierte en vector y se compara con cada documento



Cuatro maneras de convertir texto en números



Conteo

Cuenta cuántas veces aparece cada palabra.



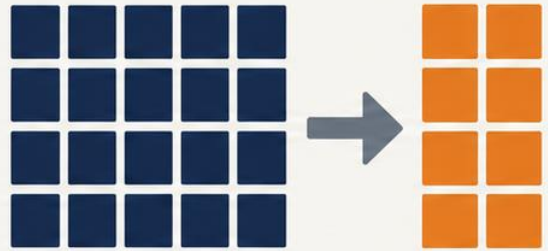
TF-IDF

Premia las palabras raras y castiga las comunes.



BM25

Puntúa con rareza, saturación y longitud del texto.



SVD

Comprime el vocabulario en 200 dimensiones latentes.

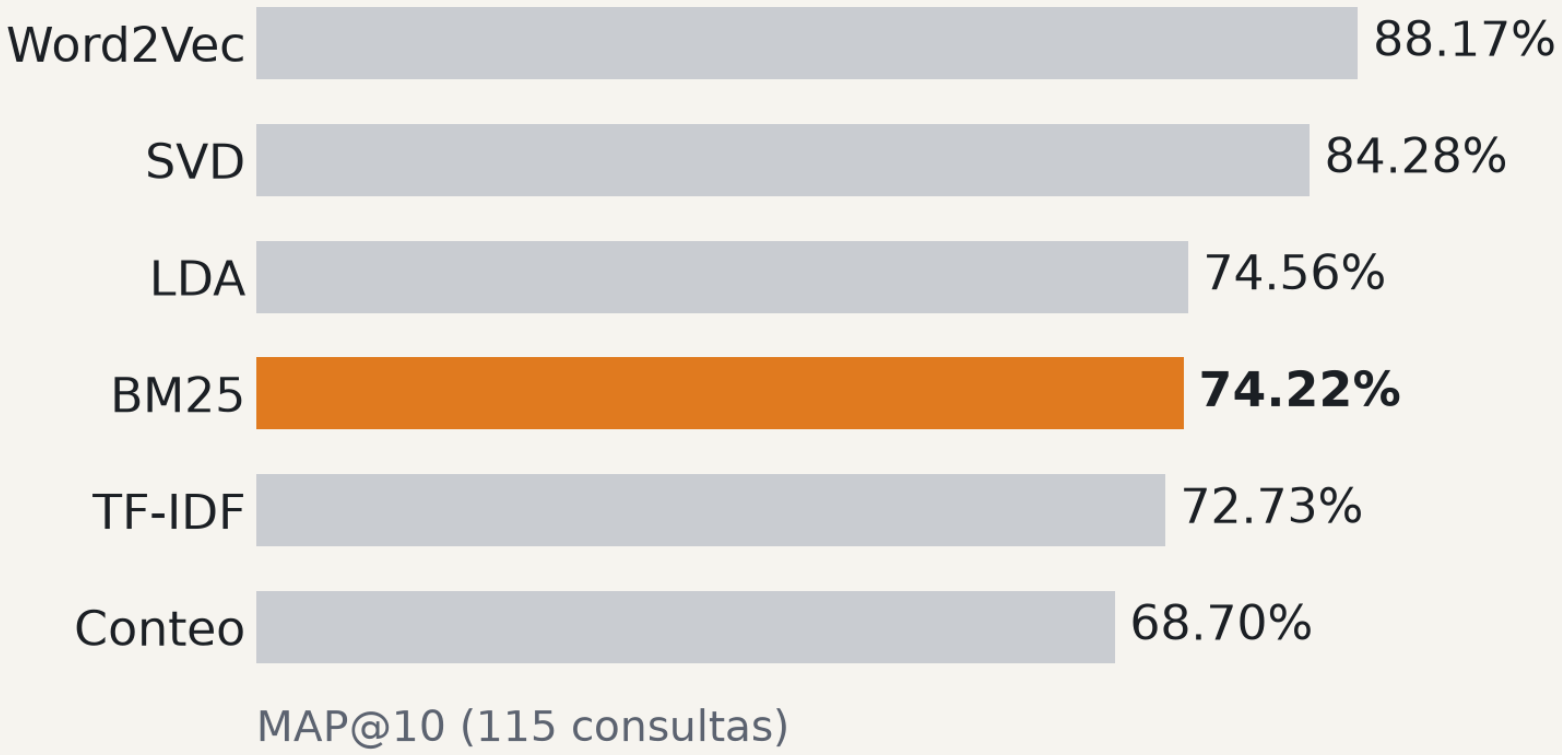
Word2Vec lidera con 88.17% de MAP@10; SVD le sigue con 84.28% y los métodos léxicos quedan atrás.

88.17%

MAP@10 de Word2Vec

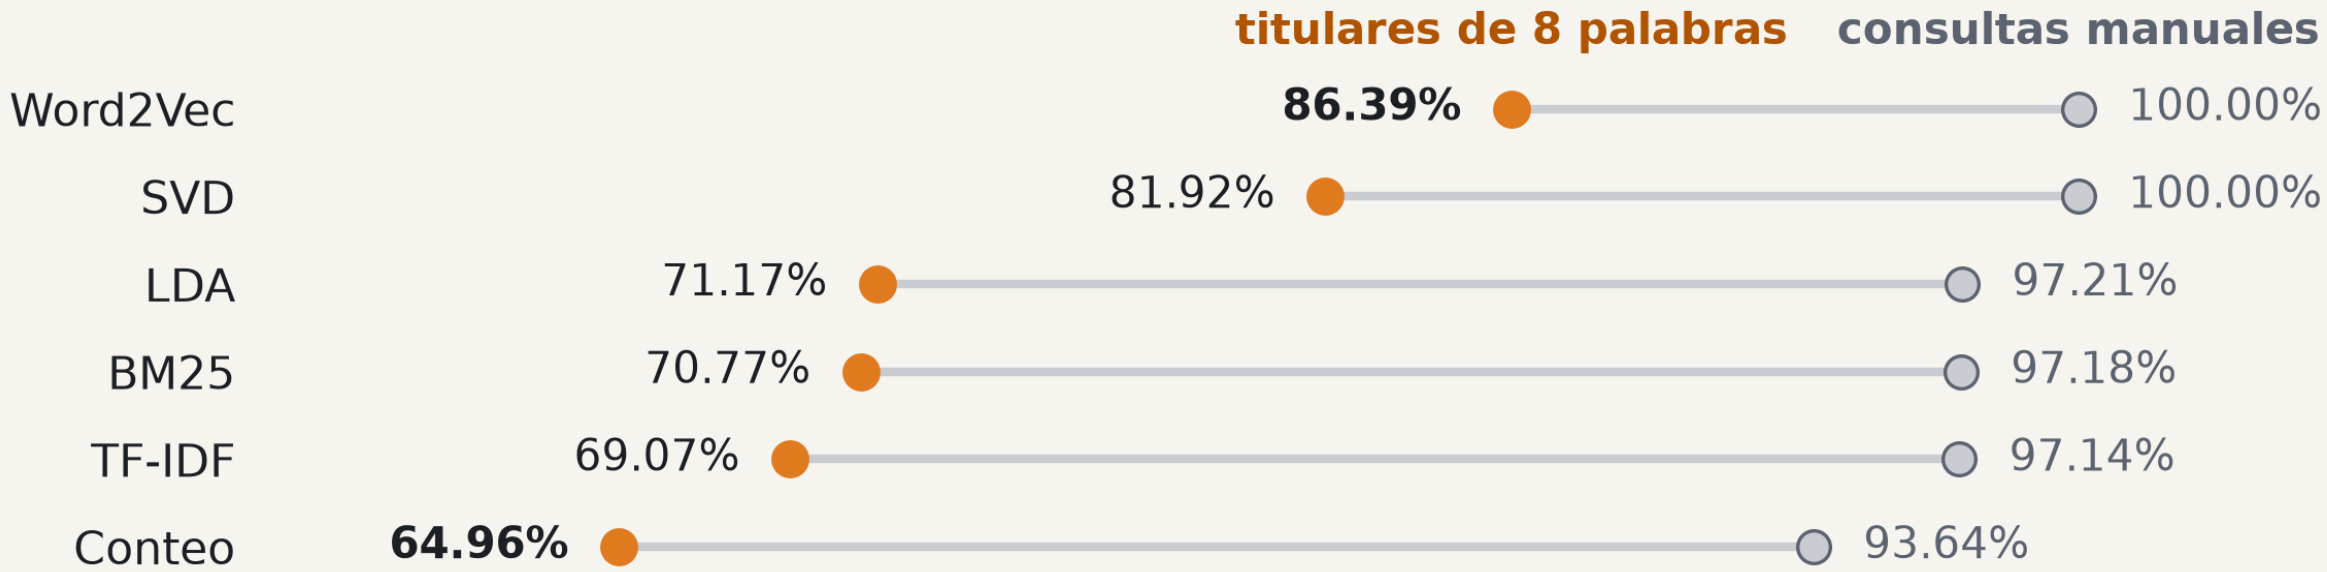
Word2Vec promedia los vectores de sus palabras (100 dimensiones). Sobre SVD su ventaja no es concluyente.

BM25 (74.22%) y TF-IDF (72.73%) rinden casi igual; solo BM25 supera con claridad al conteo (68.70%).



BM25 supera a TF-IDF por 1.49 puntos, pero el IC 95% [-0.15, 3.21] incluye 0: en la práctica empatan.

Con consultas manuales cortas casi todos aciertan; con titulares de 8 palabras Word2Vec logra 86.39% y conteo 64.96%.



Word2Vec responde a una consulta temática con tres noticias de política

election labour party vote

1
Política
ukip outspent labour on eu poll the uk

2
Política
sainsbury s labour election gift science minister lord

3
Política
top tories on lib dem hit list the

Word2Vec y SVD recuperan mejor que los métodos léxicos, aunque su diferencia aún no es concluyente.

Recomendación

Adoptar Word2Vec como método principal, conservar SVD como alternativa y validar con juicios de relevancia reales, porque aquí la categoría es solo un proxy.